HR Assistant Chatbot - Proje Anlatım ve Değerlendirme Dokümanı

1. Özet

Bu proje, kurum içi İnsan Kaynakları (İK) belgeleri üzerinden çalışan sorularını yanıtlayan bir **RAG (Retrieval-Augmented Generation)** sistemidir. Amaç, klasik chatbotlarda görülen halüsinasyon riskini azaltmak ve yanıtları belge kanıtları ile denetlenebilir hale getirmektir.

Sistem, kullanıcı sorusunu doğrudan model hafızasıyla cevaplamak yerine önce ilgili belge parçalarını bulur, ardından sadece bu bağlama dayanarak yanıt üretir.

2. Problem ve Motivasyon

Kurum politikaları (izin, yan haklar, sigorta, tescil süreçleri vb.) gibi konularda:

- Yanlış bilgi üretimi kritik hatalara yol açabilir.
- Kaynaksız yanıtlar güven yaratmaz.
- Politika değişikliklerinde statik chatbot yaklaşımı yetersiz kalır.

Bu nedenle projede hedeflenen yaklaşım:

1. Belge tabanlı bilgi erişimi
2. Kaynak gösterimli cevap üretimi
3. Ölçülebilir kalite metrikleri

3. Kapsam

Proje aşağıdaki ana fonksiyonları sağlar:

- PDF/DOCX belge yükleme ve indexleme
- Semantik ve hiyerarşik chunking
- Çok adımlı retrieval (direct + fallback zinciri)
- Kaynaklı yanıt üretimi
- Retrieval ve generation değerlendirme metrikleri
- UI üzerinden kaynakları görselleme ve doküman yönetimi

4. Yüksek Seviyeli Mimari

Sistem üç ana katmandan oluşur:

1. **Ingestion (Belge İşleme)**
2. **Retrieval (Kanıt Bulma / Grounding)**
3. **Generation (Yanıt Üretme)**

FastAPI endpoint'leri:

- `POST /documents/ingest`
- `GET /documents/`

- `GET /documents/{doc_id}/chunks`
- `DELETE /documents/{doc_id}`
- `POST /chat/`
- `POST /evaluation/*`

5. Ingestion Katmanı

5.1 Document Processing

`DocumentProcessor` PDF ve DOCX dosyalarını sayfa bazlı işler.

- PDF: metin çıkarımı + tablo ham verisi + sayfa render
- DOCX: paragraf kümeleri ile sanal sayfalama

5.2 Semantic Chunking

`HierarchicalSemanticChunker` kullanılır.

- Yapısal başlık tespiti
- Cümle segmentasyonu
- Semantik sınır tespiti (embedding + distance)
- Token limitlerine göre bölme/overlap
- Breadcrumb + parent_text zenginleştirme

5.3 Vision Extraction

Görsel ağırlıklı içeriklerin (tablo/şekil/grafik) metne dönüştürülmesi hedeflenir. Başarısız olduğunda pipeline'ın geri kalanı çalışmaya devam eder (graceful degradation).

5.4 Multi-Index Yazımı

`DocumentIndexer` iki koleksiyona yazar:

- `hr_docs_raw`: gerçek içerik chunk'ları
- `hr_docs_relatives`: chunk'lara bağlı olası soru/follow-up varyantları

Bu çift-index tasarımı, kullanıcı dilindeki varyasyonları yakalamaya yardımcı olur.

6. Retrieval Katmanı

Ana orkestratör: `SmartGroundingRetriever`

6.1 Doğrudan Arama

Önce raw index'te similarity araması yapılır.

6.2 Relatives ile Zenginleştirme

Relatives'ta eşleşen soru kayıtlarından parent raw chunk'lar çekilerek sonuç seti güçlendirilir.

6.3 Fallback Zinciri

Doğrudan sonuç yetersizse sırasıyla:

1. Query Expansion
2. HyDE
3. Query Decomposition

6.4 Grounded Kararı

Sonuçlar eşik ve minimum adet koşulunu geçmiyorsa `grounded=false` olur; generation katmanı güvenli red mesajı döner.

7. Generation Katmanı

Ana sınıf: `ResponseGenerator`

Temel prensipler:

- Cevap bağlam dışına çıkmaz.
- Cevap doğrudan verilir (sadece “bakınız” tipi yönlendirme engellenir).
- Kritik cümlelerde citation formatı beklenir.

Ayrıca düşük kaliteli “sadece yönlendirme” yanıtları için yeniden yazım (rewrite) adımı ile cevap kalitesi artırılır.

8. API ve Uygulama Katmanı

`ChatService` ile retrieval -> generation zinciri tek çağrıda orkestre edilir.

Chat çıktısı:

- `answer`
- `sources`
- `strategy_used`
- `grounded`
- `queries_tried`

Bu yapı hem debug hem denetlenebilirlik açısından değerlidir.

9. Arayüz (UI) Özellikleri

Mevcut arayüzde:

- Soru-cevap paneli
- Kaynak chip’leri
- Kaynağa tıklayınca animasyonlu belge paneli
- PDF üzerinde metin layer highlight
- Fallback (PDF açılamazsa sayfa metni/görsel)
- Chunk detay ekranı
- Doküman silme işlemleri

10. Değerlendirme Metrikleri

10.1 Retrieval

- Recall@K
- MRR
- NDCG@K

10.2 Generation

- Faithfulness
- Answer Relevancy

Bu metrikler sistemin sadece “çalıştığını” değil, “ne kadar doğru çalıştığını” takip etmek için kullanılır.

11. Güçlü Yönler

- Belge tabanlı ve kanıtlanabilir yanıt üretimi
- İleri seviye chunking tasarımı
- Çok adımlı retrieval dayanıklılığı
- API + UI + evaluation katmanlarının birlikte düşünülmesi
- Üretim kalitesini artıran rewrite ve grounding disiplinleri

12. Geliştirilmesi Gereken Yerler (Detaylı)

Bu bölüm, projenin bir sonraki sürümlerinde odaklanılması gereken teknik iyileştirmeleri içerir.

12.1 Retrieval Kalitesi ve İstikrar

Sorun:

- Eşikler (threshold) belge türüne göre fazla katı veya gevşek kalabilir.
- Bazı sorgular farklı stratejilerde alakasız chunk çekebilir.

Öneri:

- Query türüne göre dinamik threshold (ör. kısa sorgu vs uzun sorgu)
- Re-ranker (cross-encoder) ekleyerek top-k yeniden sıralama
- Source-aware score blending (raw + relatives ağırlıklı birleşim)

Beklenen Etki:

- Alakasız cevap oranında düşüş
- “No context” yanlış pozitiflerinin azalması

12.2 Citation Doğruluğu

Sorun:

- Metin içinde geçen citation sayfası ile tıklanan kaynak sayfası her durumda birebir eşleşmeyebilir.

Öneri:

- Cevap üretiminde citation’ı kaynak ID bazlı üretmek (`chunk_id`/`doc_id`/`page_num`)

- UI'da metin citation ile source objesi arasında deterministic eşleme
- "Citation verifier" adımı (cevaptaki sayfa, gerçekten ilgili chunk sayfası mı?)

Beklenen Etki:

- Kullanıcı güveninde artış
- Hatalı kaynak yönlendirmelerinin azalması

12.3 Vision Pipeline Dayanıklılığı

Sorun:

- Bazı sayfalarda vision extraction parse hataları oluşabiliyor.

Öneri:

- Vision çıktı şemasını normalize eden katman (string/list/dict güvenli dönüşüm)
- Sayfa bazlı retry/backoff
- Vision başarısızlıklarını kalite raporuna dahil etme

Beklenen Etki:

- Görsel içerik kaybının azalması
- Büyük ve karmaşık belgelerde daha stabil performans

12.4 Performans ve Maliyet Optimizasyonu

Sorun:

- Büyük belgelerde ingestion süresi ve API maliyeti artıyor.

Öneri:

- Relatives üretimini koşullu yapmak (yalnızca uzun/karmaşık chunk'larda)
- Vision'ı sayfa sınıflandırmasına göre seçici çalıştırmak
- Caching (embedding, relatives, query-level retrieval cache)

Beklenen Etki:

- Daha hızlı ingest
- Daha düşük operasyon maliyeti

12.5 Gözlemlenebilirlik (Observability)

Sorun:

- Kararların neden verildiğini (hangi fallback neden seçildi, neden grounded=false) sistematik izlemek zor.

Öneri:

- Structured logging (query_id, strategy, threshold, top scores)
- Basit dashboard metrikleri (success rate, no-context rate, median latency)

- Retrieval trace endpoint'i

Beklenen Etki:

- Debug süresinde ciddi azalma
- Model davranışının daha hızlı iyileştirilmesi

12.6 Test Kapsamı

Sorun:

- En kritik senaryoların bir kısmı entegre testle güvence altına alınmamış olabilir.

Öneri:

- End-to-end test seti (soru -> expected citation page)
- Regression testleri (daha önce düzeltilen bug'ların geri dönmesini engelleme)
- Prompt contract testleri (yasak formatların üretilememesi)

Beklenen Etki:

- Sürüm geçişlerinde daha güvenli geliştirme

12.7 Ürün Deneyimi

Sorun:

- Teknik olarak doğru olsa da kullanıcıya "neden bu cevap verildi" açıklaması her zaman yeterince açık değil.

Öneri:

- Cevap yanında "kanıt özeti" paneli
- Her citation için "bu cümleyi destekleyen chunk" önizlemesi
- Belge yönetim ekranında versiyonlama/tarih bilgisi

Beklenen Etki:

- Son kullanıcı güveni ve kullanılabilirlik artışı

13. Sonuç

Bu proje, basit bir LLM chatbot yerine kurumsal dokümanlardan beslenen, denetlenebilir ve geliştirilebilir bir **RAG bilgi asistanı** mimarisi sunmaktadır.

En kritik mimari kazanımlar:

1. Semantik-hiyerarşik chunking,
2. Çok adımlı grounding retrieval,
3. Kaynaklı ve kontrollü generation.

Bir sonraki iterasyonda retrieval kalitesi, citation doğruluğu, observability ve test kapsamı güçlendirilirse proje akademik ve kurumsal açıdan çok daha güçlü bir seviyeye taşınacaktır.